

# OLAP Metabase

---

*Univerzita Jana Evangelisty Purkyně*

*Katedra informatiky*

*2022/2023*

*Tomáš Přibil*

*Aplikovaná informatika*

# Obsah

---

- [Obsah](#)
  - [1. Databázový server](#)
  - [2. Výběr datové sady](#)
  - [3. Vytvoření multidimenzionální datové kostky](#)
    - [3.1.Tabulky dimenzí](#)
    - [3.2. Tabulka faktů](#)
  - [4. Naplnění databáze daty](#)
  - [5. Vizualizace v Metabase](#)
    - [5.1. Rozdělení káv podle země původu](#)
    - [5.2. Průměrné hodnocení káv podle země původu](#)
    - [5.3. Průměrné hodnocení káv dle odrůdy](#)
    - [5.4.Průměrné hodnocení káv dle nadmořské výšky](#)
    - [5.5. Průměrné hodnocení dle roku sklizně](#)
    - [5.6. Průměrné hodnocení káv dle počtu quakerů \(poškozená zrna\)](#)

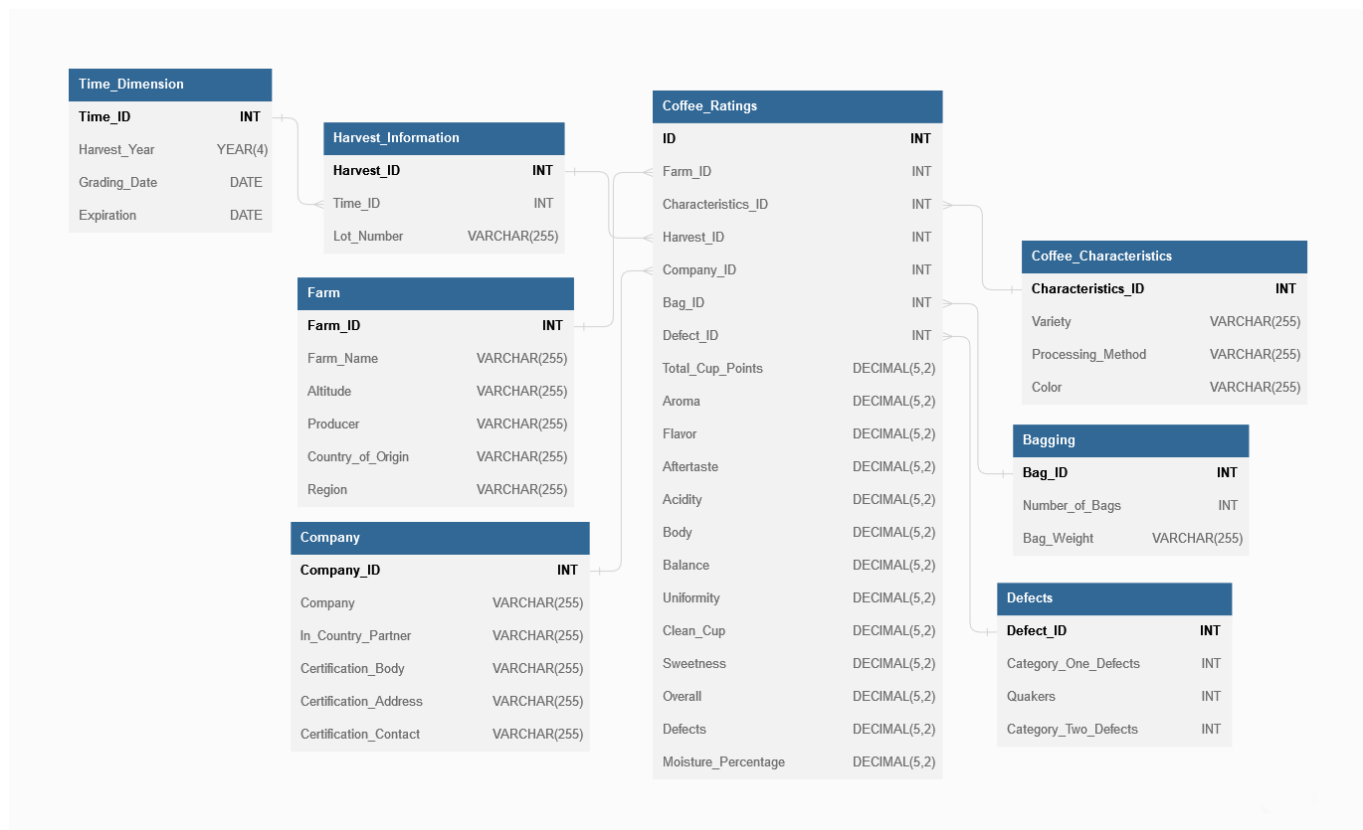
## 1. Databázový server

- Pro zpracování a manipulaci s daty byla použita databáze MySQL a pro správu byl použit nástroj phpMyAdmin.
- Celá tato infrastruktura - MySQL databáze a phpMyAdmin - byla nastavena v Dockeru, který umožňuje vytvořit izolované prostředí (kontejner), což usnadňuje nastavení a přenositelnost projektu.
- K vizualizaci a analýze dat byl použit Metabase, což je nástroj, který umožňuje snadno vytvářet grafy a dashboardy bez nutnosti psaní SQL dotazů.

## 2. Výběr datové sady

- V rámci tohoto projektu jsem se rozhodl využít dat z databáze Coffee Quality Institute (CQI). CQI je nezisková organizace se sídlem v Kalifornii, USA, která provádí širokou škálu aktivit v oblasti výzkumu, školení a certifikace s cílem zlepšit standardy kvality kávy, podporovat udržitelnost a podporovat rozvoj průmyslu se specializovanou kávou.
- Tato datová sada byla vybrána pro její rozsáhlé informace o kvalitě kávy, které pokrývají mnoho aspektů, včetně sensorických hodnocení, jako jsou aroma, chuť, dochuť, kyselost, vyváženost, čistý šálek a sladkost. Navíc sada obsahuje také data o defektech v kávových zrnech, které mohou ovlivnit její celkovou kvalitu.
- CQI spravuje databázi na svých webových [stránkách](#).
- Data v csv formátu jsou dostupná na serveru Kaggle na následujícím [odkazu](#).

## 3. Vytvoření multidimenzionální datové kostky



- CSV soubor obsahoval různé druhy informací týkající se kávových hodnocení. Cílem bylo tyto informace přerozdělit do tabulek dimenzí a tabulky faktů. Struktura databáze byla vytvořena dle struktury hvězdy.
- Výsledná databáze obsahuje 7 tabulek dimenzí.

### 3.1. Tabulky dimenzí

- Time\_Dimension - Tato tabulka obsahuje časovou dimenzi a je tvořena sloupci: Harvest\_Year (Rok sklizně), Grading\_Date (Datum hodnocení) a Expiration (Datum expirace).
- Harvest\_Information - Tato tabulka obsahuje informace o sklizni a je propojena s časovou dimenzí. Sloupce jsou: Time\_ID (ID časové dimenze) a Lot\_Number (Číslo šarže).
- Farm - Tato tabulka obsahuje informace o farmách, na kterých byla káva pěstována. Sloupce jsou: Farm\_Name (Název farmy), Altitude (Nadmořská výška), Producer (Producent), Country\_of-Origin (Země původu) a Region.
- Coffee\_Characteristics - Tato tabulka obsahuje charakteristiky kávy. Sloupce jsou: Variety (Odrůda), Processing\_Method (Způsob zpracování), Color (Barva).
- Company - Tato tabulka obsahuje informace o firmě, která kávu zpracovává a distribuuje. Sloupce jsou: Company (Název společnosti), In\_Country\_Partner, Certification\_Body, Certification\_Address a Certification\_Contact.
- Bagging - Tato tabulka obsahuje informace o balení kávy. Sloupce jsou: Number\_of\_Bags (Počet sáčků) a Bag\_Weight (Hmotnost sáčku).
- Defects - Tato tabulka obsahuje informace o defektech v kávových zrnech. Sloupce jsou: Category\_One\_Defects (Defekty první kategorie), Quakers a Category\_Two\_Defects (Defekty druhé kategorie).

### 3.2. Tabulka faktů

- Coffee\_Ratings - Tato tabulka je středem naší datové kostky. Obsahuje měřitelné hodnoty, které jsou výsledkem různých kombinací dimenzí. Sloupce jsou:
  - cizí klíče
    - ID, Farm\_ID, Characteristics\_ID, Harvest\_ID, Company\_ID, Bag\_ID, Defect\_ID
  - hodnoty hodnocení kávy
    - Total\_Cup\_Points (Celkový počet získaných bodů), Aroma (Aroma), Flavor (Chut'), Aftertaste, Acidity (Kyselost), Body, Balance, Uniformity, Clean\_Cup, Sweetness, Overall, Defects a Moisture\_Percentage.


## 4. Naplnění databáze daty

- Pro naplnění databáze byl použit skript napsaný v jazyce Python.
- použité knihovny:
  - csv - Knihovna určená pro práci s csv soubory.
  - pymysql - Rozhraní pro připojení k MySQL databázi z Pythonu. V tomto skriptu byla použita pro vytvoření spojení s databází a pro odeslání SQL příkazů pro vložení dat.
  - datetime - Knihovna, která poskytuje třídy pro manipulaci s daty a časy. Byla použita pro konverzi textových řetězců na datum
  - re - Modul regulárních výrazů v Pythonu, který je součástí standardní knihovny, byl použit k odstranění určitých znaků z datového řetězce, než byl převeden na datum.

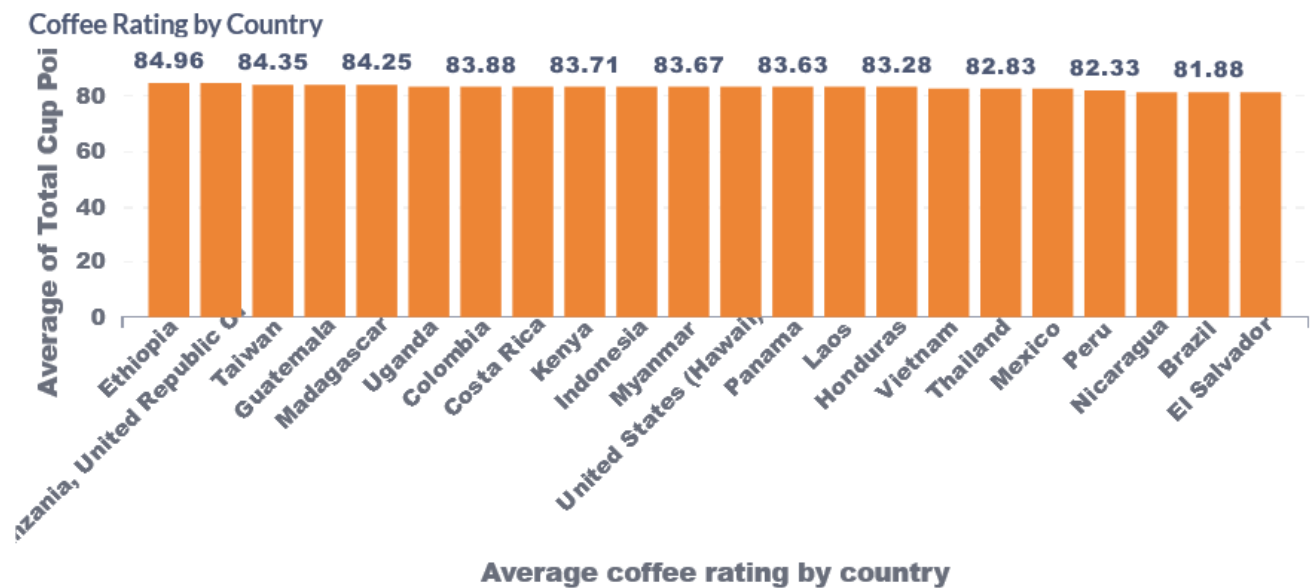
## 5. Vizualizace v Metabase

- Pro vizualizaci zpracovaných dat byl použit nástroj Metabase.


### 5.1. Rozdělení káv podle země původu




### 5.2. Průměrné hodnocení káv podle země původu



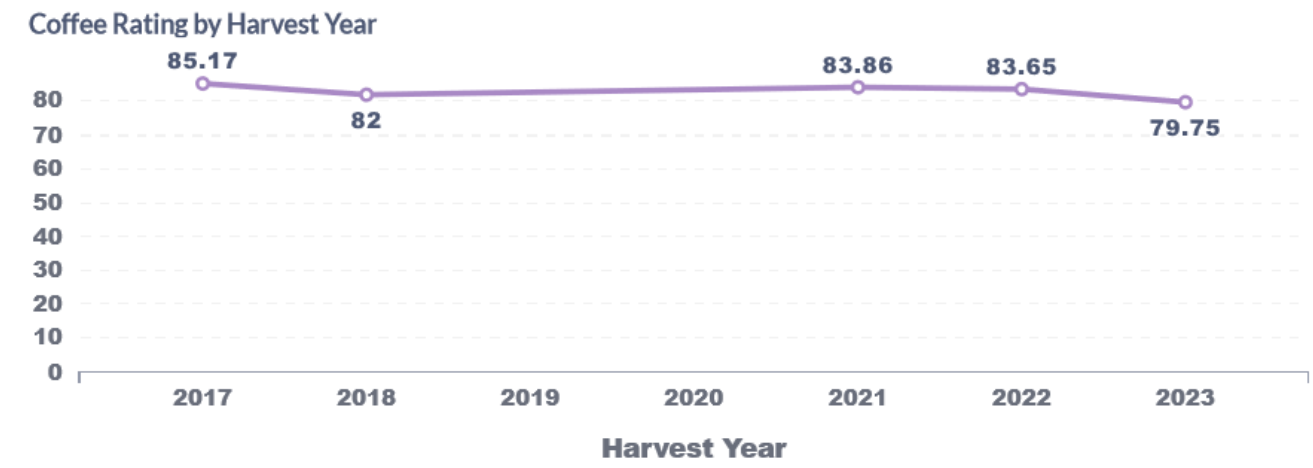
5.3. Průměrné hodnocení káv dle odrůdy



5.4.Průměrné hodnocení káv dle nadmořské výšky



5.5. Průměrné hodnocení dle roku sklizně



5.6. Průměrné hodnocení káv dle počtu quakerů (poškozená zrna)

